SIICUSP

Instituto de Matemática, Estatística e Ciência da Computação — USP

Estudo de Duplicações em Subsistemas do Kernel Linux: Análise, Refatoração e Contribuições

Guilherme Ivo • **Gabriel Almeida** • **Natália Salvino André** • **Paulo Meirelles**

{guilherme.bozi, gabrielsousa230}@usp.br

Objetivos

O kernel Linux é um dos maiores projetos de software livre, com crescimento contínuo em tamanho e número de contribuidores. Este trabalho investiga **duplicações de código no kernel Linux** com apoio da ferramenta **ArKanjo**, buscando:

- identificar duplicações e selecionar casos com potencial de refatoração;
- aplicar técnicas de refatoração considerando critérios de manutenibilidade;
- propor e submeter patches à comunidade;
- documentar interações com mantenedores e os aprendizados do processo.

Estudo e Procedimentos

O estudo foi realizado nos subsistemas **AMDGPU** e **IIO**, em duas fases:

1. **Identificação e seleção**
   Detecção de duplicações com 90% e 100% de similaridade e análise do potencial de refatoração.
2. **Implementação e submissão**
   Desenvolvimento dos patches, submissão aos mantenedores e realização dos ajustes solicitados.

Por meio de **observação participante**, os autores interagiram com a comunidade e acompanharam alunos de MAC0470/5856 Desenvolvimento de Software Livre (USP, 2026) na submissão de patches.

Conclusões

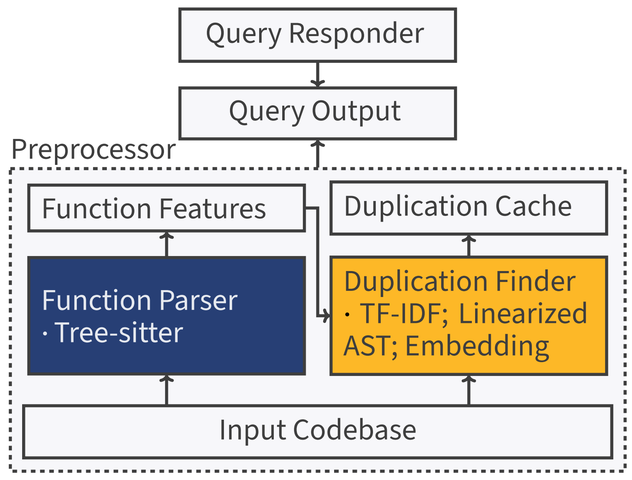
A identificação automática de duplicações é apenas o primeiro passo para contribuir ao kernel, exigindo **análise do contexto e interação com a comunidade** para avaliar possíveis refatorações.

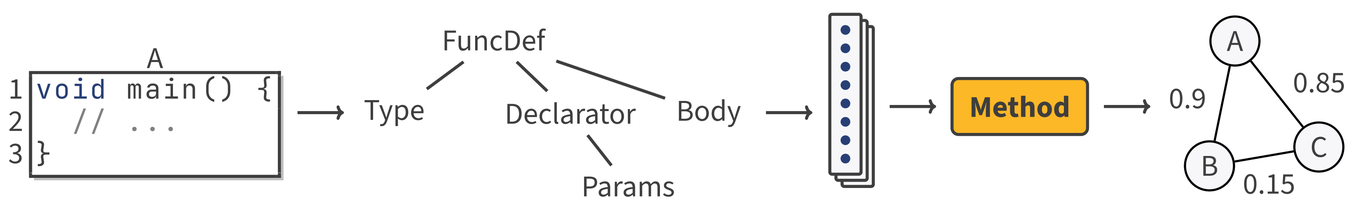
A reavaliação dos **takeaways** mostrou que eles caracterizam os casos e revelou um possível **novo padrão**. O ArKanjo mostrou útil para explorar a base do kernel e descobrir oportunidades de contribuição.

Ferramenta ArKanjo

O **ArKanjo** utiliza uma arquitetura em dois estágios. Neste trabalho, foi aprimorada a ferramenta com:

- **Tree-sitter**, para análise baseada em AST e suporte a diferentes linguagens;
- mais métodos de similaridade;
- melhorias na extensibilidade e nas **saídas estruturadas**.





Resultados — Submissão de Patches

10	4	2	1
Aceitos	Rejeitados	Sem respostas	Abandonado
+1.619/-2.758	+302/-470	+128/-189	+42/-60

Os **4 takeaways** do estudo dos patches de 2025[1] foram reavaliados em novos patches para verificar capacidade de caracterizar situações de aplicação do princípio *Don't Repeat Yourself*. A análise indica um novo padrão: **Takeaway T5** (Abstraction Scope), no qual os mantenedores rejeitam uma deduplicação quando a camada compartilhada proposta cobriria componentes aos quais o código não se aplica.

T1 Driver Forking — 7 patches

"Additional to that the separation was intentional."

T2 Readability — 5 patches

"This feels like a helper that doesn't necessarily add much value."

T3 Integration Overhead — 3 patches

"[...] if this was worth doing. To me it feels of marginal benefit."

T5 Abstraction Scope — 5 patches

"Please [...] move them a layer up instead of messing up the backends."

Nenhum caso foi fortemente associado **Takeaway T4** (Performance), que estabelece que nenhum mantenedor rejeitou um patch por questões de desempenho.

[1] L. Arcanjo, D. Tadokoro, M. Spessoto, R. Passos, and P. Meirelles. When Do You RepeatYourself? Voices from the Trenches of Linux Kernel Maintainers on Code Duplication, 2026.

REPOSITÓRIO

FAPESP
FUNDAÇÃO DE AMPARO À PESQUISA DO ESTADO DE SÃO PAULO

IME USP